

## Q1.教師あり学習、教師なし学習、強化学習の特徴についてまとめよ。

### 教師あり学習

学習データのデータ点と正解ラベル(データ)がどちらもあらかじめ与えられている、機械学習の枠組み。

教師なし学習に比べて、あらかじめデータにアノテーションをしなくてはいけないため、手間がかかるがデータの傾向が学習データと正解データで似ている場合は高い精度を発揮する。与えられた学習データと正解ラベルの傾向と大きく異なるデータが予測対象に含まれている場合は正しく正解をすることができない。

また、データ量に比べて、データの次元が大きすぎると過学習を起こしてしまう。手法としてはSVM、ナイーブベイズ、ランダムフォレストなどがあげられる。

### 教師なし学習

学習データのデータ点のデータのみが与えられていて、最もよくデータを分離できる境界面をデータの分布に基づいて逐次更新していく枠組み。

あらかじめデータ点の正解データを用意しなくて済むため、手間はかからないが、出力データの値がどのようなになるか、結果がどのくらい高精度かを判断することができない。また一般的に教師あり学習に比べて精度が低くなる。

手法としてはt-SNE、k-means、PCAなどがあげられる。

### 強化学習

ある環境内におけるエージェントが現在の状況を観測することによって、とるべき行動を選択する機械学習の枠組み。

環境内には行動に応じた報酬が設計されており、その報酬が最大になるように行動を繰り返して学習していく。

失敗を前提にした学習モデルなので、トライアンドエラーが繰り返せる環境であることや、行動パターンを報酬とモデルに落とし込めるような枠組みで使うことが望まれる。アルゴリズムは動的計画法に類似していると言える。

動的計画法と異なる点としては、次の行動の期待値があらかじめわかっていないことが挙げられる。例えば株価の予測モデルで、翌日の株価の値などはまだ決まっていないため、直接的に期待値として用いることはできない。

手法としてはQ学習、モンテカルロ法、Sarsaなどがあげられる。

**Q2.教師あり学習、教師なし学習、強化学習のそれぞれについて、講義では扱わなかったアルゴリズムを調べ、その概要をまとめなさい。**

教師あり学習...

ランダムフォレスト

決定木による複数の弱学習機を統合させて汎化性能を向上させるアンサンブル学習アルゴリズム。まず決定木について説明する。決定木はデータの特徴量ごとに境界を決め分岐を作り、これをノードとした木を構築しデータを分類する機械学習モデルである。木を構築するためのアルゴリズムは複数種類あり、一般的に木のノードを通すことでうまくラベルを分類できるようにしていく。例えば分岐(ノード)を通す前のラベルのエントロピーと分岐(ノード)を通した後のエントロピーの差分をとり、その差分が大きいノードを有用なものとして残していくことで木を構築する。ランダムフォレストはこの決定木を複数並行に構築し、それぞれの木の答えを多数決することで決める。

教師なし学習...

SNE

高次元データを低次元データに写像する(=次元圧縮する)教師なし学習アルゴリズム。これは写像先のデータ点と写像元のデータ点に距離を定義し、この距離が近くなるようにするアルゴリズムである。具体的には以下の式で表される。

高次元データでのデータ点 $j,i$ の距離

$$p_{j|i} = \exp \frac{\left( -\frac{\|x_i - x_j\|^2}{2\sigma_i^2} \right)}{\sum_{k \neq i} \exp \left( \|x_i - x_k\|^2 \right)}, p_{i|i} = 0$$

低次元データでのデータ点 $j,i$ の距離

$$q_{j|i} = \exp \frac{\left( -\frac{\|y_i - y_j\|^2}{2\sigma_i^2} \right)}{\sum_{k \neq i} \exp \left( \|y_i - y_k\|^2 \right)}, q_{i|i} = 0$$

この $p_{j|i}, q_{j|i}$ は確率分布なため、これらの近さを同じにするにはKLダイバージェンスを損失関数 $C$ とし、 $C$ が最小となるように最急降下法によって圧縮後の点 $y_i$ の座標を更新する。

強化学習...Sarsa

授業で習ったQ学習はQ値を以下の遷移式で学習していく

$$Q(S_t, a_t) \leftarrow (1 - \alpha)Q(S_t, a_t) + \alpha(r_{t+1} + \gamma \max_{a+1} Q(S_{t+1}, a_{t+1}))$$

この式の意味としては、現在の行動によって得られる次の状態の価値の中でも最大値を使って現在の価値を評価するというものである。

これに対して Sarsa は以下のような式で与えられる。

$$Q(S_t, a_t) \leftarrow (1 - \alpha)Q(S_t, a_t) + \alpha(r_{t+1} + \gamma Q(S_{t+1}, a_{t+1}))$$

こちらの式は現在の価値は次の行動を実際に起こしてみてもどのような値が得られるか実験してから決めるというものである。

Q 学習に比べより正確な値が得られるが、現在の値を更新するためにエージェントが実際にもう一度行動を行う必要があるため計算の効率は落ちる。

**Q3. 教師あり学習、教師なし学習、強化学習のうち、2つ以上を組み合わせることを考える。あなた自身で組み合わせを1つ選んで、これによってできるようになること、その組み合わせ方、用途などについて論じなさい。（A4 半ページ程度。）**

教師なし学習を用いてデータをクラスタリングし、それを特徴量に教師あり学習をすることを提案する。例えば東京都の賃貸の賃料を予測するモデルを作成するとする。この際にあらかじめ教師データに面積、緯度・経度、築年数・間取りなど、教師ラベルに賃料が一部与えられているとする。

この時地域における賃料の変動をより直接的にモデルに理解させるために、緯度経度・面積を特徴量として k-means を用いることで場所、面積が近いデータごとのクラスタリングラベルを取得する。このラベルを特徴量として加えることでより学習データをリッチなものにし精度向上を狙う。またこのラベルをキーとしてデータを集約し統計量をとることで賃料との相関が高い特徴を得ることができる

(ex. 高級住宅街かつ面積が広いクラスターの平均賃料、最低賃料、最大賃料、賃料の分散など)

クラスターごとの分散を得ることができれば、それにより予測モデルの予測値の値もある程度目安をつけることができる。クラスター内の分散が小さければ、他の情報を絡めて総合的に賃料を予測するよりも、そのクラスターの平均賃料などの特徴量の比重を大きくして予測した方が精度が高いなど見当がつけられる。

この手法は実際に下記のオンラインのデータ分析コンペティションに参加した際に使用した。結果として 342 チーム中 9 位の成績を収めた。

<https://signate.jp/competitions/182>

#### 問 4 授業の感想

昨今は深層学習ライブラリなどの開発が進み、よく分からなくても高度な計算ができてしまいますが、実際に機械学習の基礎に立ち返り、数式と睨めっこしながら簡単な問題を解いていくことでより機械学習について深く理解し、面白さに改めて気づくことができました。

PRML も頑張ってみようと言う気持ちになれる程度には、理解ができるようになりました。この授業の続編もあればぜひ受講してみたいです。ありがとうございました。